

Análise e Previsão de Execução Orçamentária em Despesas Públicas: Um Estudo de Caso Aplicado à FACAPE (2021–2025)

Sistemas de Informação e Ciência de Dados

Faculdade de Ciências Aplicadas e Sociais de Petrolina (FACAPE)
Petrolina, PE, Brasil

Resumo— A eficiência na execução orçamentária é um pilar crítico para a governança e sustentabilidade de autarquias públicas de ensino superior. Este trabalho apresenta um estudo de caso aplicado às despesas da Faculdade de Ciências Aplicadas e Sociais de Petrolina (FACAPE) entre 2021 e 2025, utilizando o framework CRISP-DM para analisar e antever inconsistências e falhas na liquidação de empenhos contratuais. A partir de um ecossistema de dados composto por 973 registros históricos consolidados, foi implementada uma abordagem metodológica em três frentes: classificação supervisionada com validação temporal (out-of-time) para predição de contratos problemáticos (pagamentos sub-70% ou anulações), detecção de anomalias via algoritmos não supervisionados e agrupamento estrutural (clustering). O modelo Random Forest obteve o melhor desempenho preditivo, alcançando F1-Score de 0,774 e AUC-ROC de 0,893. O mapeamento identificou 10% de contratos anômalos e subdividiu os fornecedores em três faixas de risco bem delimitadas. Adicionalmente, desenhou-se um modelo de monitoramento contínuo baseado em Evidently AI, PostgreSQL e Grafana para mitigar o data drift. Os resultados demonstram o potencial analítico da ciência de dados na mitigação de riscos fiscais e no aprimoramento do planejamento orçamentário público.

Palavras-chave— Finanças Públicas, CRISP-DM, Aprendizado de Máquina, Execução Orçamentária, Detecção de Anomalias.

I. INTRODUÇÃO

A gestão de recursos no ecossistema da administração pública brasileira exige aderência a princípios rígidos de legalidade, impessoalidade, moralidade, publicidade e eficiência, conforme preconiza o Art. 37 da Constituição Federal. No âmbito das autarquias municipais de ensino superior, como a Faculdade de Ciências Aplicadas e Sociais de Petrolina (FACAPE), o alinhamento entre o planejamento orçamentário e a execução financeira direta é crucial para garantir a perenidade das operações acadêmicas e administrativas.

Tradicionalmente, a análise de despesas públicas concentra-se em avaliações ex-post, ou seja, auditorias realizadas após a consolidação dos gastos. Contudo, esse formato reativo limita a capacidade dos gestores de intervir preventivamente em contratos que apresentam desvios de execução, tais como subutilização crônica de recursos empenhados ou a necessidade recorrente de anulações parciais. Contratos com execução problemática geram ineficiência alocativa, travando orçamentos que poderiam suprir outras demandas institucionais urgentes.

Com o advento da Ciência de Dados e a disseminação de frameworks metodológicos estruturados como o CRISP-DM (*Cross-Industry Standard Process for Data Mining*), tornou-se viável converter registros brutos de portais de transparência em ferramentas preditivas e prescritivas de tomada de decisão.

III. METODOLOGIA

A. Validação Temporal Out-of-Time

Modelos de previsão em finanças públicas não devem ser validados por validação cruzada *k-fold* aleatória tradicional, uma vez que a quebra da ordem cronológica introduz viés de antecipação temporal.

Para mitigar esse fator, adotou-se uma estratégia rigorosa de validação temporal *out-of-time*. O conjunto de dados foi cindido com base nos anos fiscais: os registros emitidos entre 2021 e 2023 foram alocados exclusivamente para a etapa de treinamento e ajuste de hiperparâmetros dos modelos (65% do volume global). Em contrapartida, os dados dos anos de 2024 e 2025 foram completamente isolados para atuar como o conjunto de teste e validação final (35% do volume), refletindo de forma fidedigna a capacidade de generalização do sistema frente a novos exercícios econômicos.

B. Algoritmos Avaliados

Seis abordagens distintas de classificação foram testadas para a modelagem preditiva: Regressão Logística com regularização Lasso (L1), Support Vector Machines (SVM) com kernel linear, K-Nearest Neighbors (KNN), Gradient Boosting Machine (GBM), Random Forest de topologia profunda (Deep RF) e Random Forest com restrição de profundidade (Shallow RF).

Este artigo descreve o desenvolvimento e a implantação de uma solução de inteligência de dados aplicada às despesas da FACAPE no quinquênio 2021–2025. O principal objetivo consiste em classificar de forma antecipada, no ato da assinatura ou emissão de um novo empenho, se o respectivo contrato incorrerá em uma **execução problemática** — definida formalmente neste trabalho como a ocorrência de um volume de pagamento final abaixo de 70% do montante originalmente empenhado ou pela presença de termos de anulação parcial do valor contratual.

Para além do escopo estritamente preditivo, a pesquisa expande a análise por meio de técnicas não supervisionadas de detecção de anomalias (Isolation Forest) e segmentação de perfis de risco (K-Means), culminando no desenho de uma arquitetura moderna de monitoramento de produção com detecção de *data drift*.

II. COMPREENSÃO E PREPARAÇÃO DOS DADOS

A. Coleta e Consolidação do Dataset

O conjunto de dados brutos foi extraído diretamente do sistema contábil e de transparência da FACAPE, composto por 5 arquivos em formato JSON correspondentes aos exercícios financeiros de 2021, 2022, 2023, 2024 e 2025. Cada arquivo consolida o fluxo de movimentação das despesas públicas em suas diferentes fases: empenho, liquidação, pagamento e anulação.

O processo inicial de engenharia de dados envolveu a leitura, normalização das estruturas aninhadas dos arquivos JSON e a unificação em um único repositório relacional. Após a exclusão de registros duplicados e correções de inconsistências textuais primárias, obteve-se um universo de 973 contratos/registros válidos de empenho individualizados para processamento.

B. Engenharia de Atributos e Lookback Temporal

Para simular com realismo a atuação do modelo em ambiente de produção e evitar cenários de *data leakage* (vazamento de dados futuros), os atributos preditivos foram divididos estritamente entre dados estáticos do empenho atual e dados históricos retroativos acumulados do respectivo prestador de serviço (fornecedor).

A técnica de *lookback temporal* computou, para cada ano corrente t , o histórico de comportamento do fornecedor nos anos anteriores ($t-1$, $t-2$, $\dots$). As variáveis finais estruturadas para o treinamento foram:

- **valor_empenhado_log**: Logaritmo natural do valor empenhado, estabilizando a variância de valores extremos;

C. Modelagem Não Supervisionada Complementar

Para enriquecer a tomada de decisão, duas abordagens não supervisionadas foram acopladas ao fluxo:

- 1) *Detecção de Anomalias*: Aplicação do algoritmo Isolation Forest no espaço multidimensional de recursos para isolar empenhos discrepantes que fujam do padrão operacional ordinário da FACAPE.
- 2) *Clustering*: Implementação do algoritmo K-Means nos dados consolidados dos fornecedores para segmentá-los em grupos homogêneos de risco, permitindo a criação de políticas de governança customizadas por faixa. O número ideal de clusters ($k=3$) foi validado pelas metodologias do Cotovelo (*Elbow Method*) e Índice de Silhueta.

IV. RESULTADOS E DISCUSSÃO

A. Desempenho dos Modelos de Classificação

Após a execução dos seis experimentos controlados no conjunto de teste temporal (2024–2025), a arquitetura baseada em Random Forest com árvore rasa (Shallow RF) despontou como a solução mais eficiente e equilibrada. Os resultados comparativos detalhados encontram-se sumarizados na Tabela I.

Tabela I					
Métricas Comparativas dos Modelos na Validação Out-of-Time					
Modelo Experimental	Acurácia	Precision	Recall	F1-Score	AUC-ROC
Regressão Logística (L1)	0,782	0,710	0,685	0,697	0,812
SVM Linear	0,765	0,692	0,660	0,676	0,798
KNN (k=5)	0,741	0,654	0,612	0,632	0,735
GBM (Gradient Boosting)	0,814	0,762	0,740	0,751	0,874
Deep Random Forest	0,802	0,745	0,768	0,756	0,881
Shallow Random Forest	0,835	0,789	0,760	0,774	0,893

O modelo Shallow RF obteve um F1-Score de 0,774 e uma Área Sob a Curva ROC de 0,893. A imposição de restrição na profundidade máxima das árvores reduziu sensivelmente o sobreajuste (overfitting) observável na variação estável "Deep RF", conferindo maior robustez e capacidade de generalização ao lidar com flutuações orçamentárias típicas da transição de anos fiscais.

A extração da importância das características (*Feature Importance* via ganho de impureza de Gini) revelou que a variável **valor_empenhado_log** foi o preditor isolado

- **tipo**: Variável binária identificando a natureza jurídica do fornecedor (Pessoa Física - PF ou Pessoa Jurídica - PJ);
- **perc_retido**: Percentual do valor liquidado que foi retido em juízo ou por obrigações fiscais ($\frac{\text{valor_retido}}{\text{valor_liquidado}}$);
- **perc_saldo**: Razão entre o saldo remanescente não pago e o valor empenhado original;
- **hist_taxa_execucao**: Média histórica da taxa de execução financeira ($\frac{\text{valor_pago}}{\text{valor_empenhado}}$) do fornecedor em contratos anteriores;
- **hist_anos_ativo**: Quantidade de anos prévios em que o fornecedor registrou contratos com a autarquia;
- **hist_perc_anulacao**: Proporção histórica de empenhos do fornecedor que sofreram anulações parciais ou totais;
- **fornecedor_novo**: Flag booleana indicando se o fornecedor está operando pela primeira vez junto à instituição.

C. Análise Exploratória e Definição do Alvo

A variável dependente (alvo) foi formalizada de forma binária ($Y \in \{0, 1\}$), onde a classe $Y = 1$ denota uma Execução Problemática, configurada matematicamente por:

$$Y = 1 \text{ iff } \left(\frac{\text{Valor_Pago}}{\text{Valor_Empenhado}} < 0.70 \right) \text{ or } \left(\text{Valor_Anulado} > 0 \right)$$

A análise exploratória dos dados (EDA) revelou forte assimetria na distribuição dos montantes financeiros e indicou que cerca de 22% do volume total de empenhos emitidos pela instituição historicamente enquadram-se nos critérios de execução problemática, demonstrando um desbalanceamento moderado que requer métricas robustas de avaliação, como F1-Score e a Área Sob a Curva ROC (AUC-ROC), preterindo a acurácia global simples.

mais relevante, respondendo por 34% do peso total da decisão algorítmica. Essa evidência confirma o impacto que o porte financeiro do empenho exerce sobre o risco de desvio e de renegociação contratual na autarquia.

B. Detecção de Anomalias (Isolation Forest)

O algoritmo Isolation Forest mapeou e classificou 98 contratos como legítimas anomalias multidimensionais, o que equivale a aproximadamente 10% do banco de dados total analisado.

O caso mais expressivo e severo de desconexão estatística identificado pelo algoritmo envolveu o registro classificado textualmente como "FOPAG PROFESSOR EFETIVO" (Folha de Pagamento de Docentes Concursados). Esta entidade apresentou um montante empenhado de R\$ 11,7 milhões, associado a uma taxa de execução final de apenas 46% e a um índice atipicamente elevado de retenção de valores na ordem de 36%. Do ponto de vista administrativo, esse evento denota imprecisões severas de estimativa orçamentária inicial para despesas compulsórias de pessoal, justificando plenamente o alerta de alta criticidade emitido pelo modelo.

C. Análise por Segmentos de Risco (K-Means)

A clusterização dividiu a base de fornecedores históricos em três partições estruturais nítidas e complementares, permitindo estratificar o risco orçamentário. As características consolidadas dos perfis gerados estão dispostas a seguir:

- **Cluster 0 (Alto Risco):** Composto por 111 fornecedores de grande porte. Apresenta o maior valor médio contratado (R\$ 803.000,00) e exibe uma alarmante taxa média de anulação parcial de 39%. Este grupo concentra os contratos críticos de infraestrutura, tecnologia e grandes prestadores de serviços continuados.
- **Cluster 1 (Médio Risco):** Agrupa 196 fornecedores institucionais, registrando um ticket financeiro médio de R\$ 25.000,00 e incidência controlada de anulação na casa de 1,7%.
- **Cluster 2 (Baixo Risco):** Segmento majoritário com 297 fornecedores de pequeno porte ou contratações diretas por dispensa de licitação. Registra valor médio reduzido (R\$ 11.000,00) e índice marginal de anulação de apenas 1,1%.

V. ARQUITETURA DE MONITORAMENTO

Para assegurar a longevidade operacional do modelo preditivo Shallow RF e resguardá-lo contra a degradação natural de performance decorrente de mudanças macroeconômicas ou legislativas, desenhou-se uma infraestrutura de monitoramento contínuo em produção fundamentada em três camadas tecnológicas integradas.

O motor de avaliação de desvios baseia-se na biblioteca *Evidently AI*, encarregada de computar periodicamente testes estatísticos de Kolmogorov-Smirnov e a divergência de Population Stability Index (PSI) para monitorar a ocorrência de *data drift* nas variáveis preditivas (notadamente no comportamento de *valor_empenhado_log*) e de *concept drift* na variável alvo.

Todas as inferências executadas em tempo de execução, associadas aos seus respectivos metadados de entrada e métricas de desvio temporal, são persistidas de forma estruturada em tabelas de log dentro de um banco de dados relacional *PostgreSQL*. Por fim, a camada de visualização consome os dados históricos compilados no banco através de um painel dinâmico construído no *Grafana*, configurado com gatilhos automáticos de notificação (via Webhooks) para alertar a equipe de TI e governança da FACAPE caso o índice F1-Score do modelo em produção apresente queda superior a 10% em relação ao baseline de teste.

[Fim do Documento Técnico-Científico — Padrão IEEE/
ABNT]

VI. CONCLUSÃO

A aplicação sistemática do framework CRISP-DM sobre os dados orçamentários da FACAPE demonstrou-se viável e altamente preditiva. A modelagem através do algoritmo Shallow Random Forest obteve êxito na identificação prévia de empenhos com alta probabilidade de sofrerem execução deficitária ou interrupções por anulação, viabilizando uma governança pública ativa e preventiva. O acoplamento de análises de anomalias e agrupamentos forneceu aos gestores uma taxonomia clara para priorização de auditorias internas.

Como principal limitação técnica do estudo, destaca-se a dependência estritamente focada em variáveis financeiras internas e quantitativas, omitindo fatores contextuais relevantes tais como a modalidade de licitação empregada (pregão eletrônico, concorrência, inexigibilidade) e indicadores macroeconômicos locais (inflação de serviços e índices setoriais).

Para trabalhos futuros, propõe-se a expansão do dataset através do enriquecimento de dados via Processamento de Linguagem Natural (PLN), aplicando técnicas de extração de entidades (NER) e embeddings semânticos sobre os textos descritivos dos objetos dos empenhos para capturar nuances qualitativas de risco. Adicionalmente, planeja-se a automação do pipeline de retreinamento contínuo do modelo estimulado pelos gatilhos de drift mapeados no Grafana.

AGRADECIMENTOS

Os autores expressam seu agradecimento à equipe técnica e administrativa do setor de licitações e contabilidade da FACAPE pelo fornecimento e abertura das bases de dados necessárias à consecução deste estudo de caso científico.

REFERÊNCIAS

- [1] Brasil. *Constituição da República Federativa do Brasil de 1988*. Artigo 37. Brasília, DF, 1988.
- [2] P. Chapman, J. Clinton, R. Kerber, T. Khabaza, T. Reinartz, C. Shearer, and R. Wirth, *CRISP-DM 1.0: Step-by-step data mining guide*. SPSS inc, 2000.
- [3] L. Breiman, "Random Forests," *Machine Learning*, vol. 45, no. 1, pp. 5-32, 2001.
- [4] F. T. Liu, K. M. Ting, and Z. H. Zhou, "Isolation Forest," in *Proceedings of the 2008 Eighth IEEE International Conference on Data Mining*, 2008, pp. 413-422.
- [5] J. MacQueen, "Some methods for classification and analysis of multivariate observations," in *Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability*, 1967, vol. 1, pp. 281-297.