

Análise e Predição de Execução Orçamentária em Despesas Públicas: Um Estudo de Caso Aplicado à FACAPE (2021–2025)

Caio Lassalvia, José Davidson, Vinicius de Carvalho
Curso de Ciência da Computação
Disciplina de Ciência de Dados
Faculdade de Petrolina (FACAPE)
Petrolina, PE, Brasil

Me. Mateus Silva (Orientador)
Curso de Ciência da Computação
Faculdade de Petrolina (FACAPE)
Petrolina, PE, Brasil

Resumo—A eficiência na execução orçamentária constitui um pilar fundamental para a governança e a sustentabilidade financeira de autarquias públicas de ensino superior. Este trabalho apresenta um estudo de caso aplicado às despesas da Faculdade de Ciências Aplicadas e Sociais de Petrolina (FACAPE) no período compreendido entre 2021 e 2025. Utilizou-se o framework metodológico CRISP-DM (*Cross-Industry Standard Process for Data Mining*) para a análise e a inferência de inconsistências e falhas na liquidação de empenhos contratuais. A partir de um *dataset* consolidado de 1.870 registros históricos (via MCP-Brasil), implementou-se uma abordagem analítica tripartida: classificação supervisionada com validação temporal (*out-of-time*) para a predição de execuções problemáticas, detecção de anomalias via algoritmos não supervisionados e agrupamento estrutural (*clustering*). O algoritmo *Logistic Regression* obteve desempenho preditivo robusto para o cenário atual, alcançando uma AUC-ROC de 0,73. O mapeamento multidimensional identificou 10% de contratos anômalos, com destaque para distorções em folhas de pagamento. Adicionalmente, propõe-se uma arquitetura de monitoramento contínuo fundamentada em *Evidently AI*, *PostgreSQL* e *Grafana* para a mitigação de *data drift*.

Index Terms—Finanças Públicas, CRISP-DM, Machine Learning, Execução Orçamentária, Detecção de Anomalias.

I. INTRODUÇÃO

A gestão de recursos no ecossistema da administração pública brasileira demanda estrita observância aos preceitos constitucionais de legalidade, impessoalidade, moralidade, publicidade e eficiência (Art. 37, CF/88). No contexto das autarquias municipais de ensino superior, como a Faculdade de Petrolina (FACAPE), a convergência entre o planejamento orçamentário e a execução financeira é imperativa para assegurar a perenidade das operações acadêmicas e administrativas.

Historicamente, a análise de despesas públicas tem se pautado em avaliações *ex-post*, caracterizando-se por auditorias reativas após a consolidação dos gastos. Tal paradigma limita a capacidade de intervenção preventiva em contratos que apresentam desvios de execução. Com a ascensão da Ciência de Dados e a padronização de ciclos de vida de mineração de dados como o CRISP-DM, torna-se factível a transformação de registros brutos em ativos preditivos.

II. COMPREENSÃO E PREPARAÇÃO DOS DADOS

A. Coleta e Consolidação do Dataset

O *corpus* de dados foi extraído dinamicamente via **MCP-Brasil**, conectando-se ao sistema SAGRES do TCE-PE, abrangendo os exercícios de 2021 a 2025. Após o saneamento e unificação, obteve-se um universo de **1.870 registros válidos** de empenho.

B. Engenharia de Atributos e Lookback Temporal

Aplicou-se a técnica de *lookback* temporal para evitar *data leakage*, computando preditores históricos como a `hist_taxa_execucao` e `hist_anos_ativo`. A variável `valor_empenhado_log` foi identificada como o preditor de maior impacto, detendo **96% de importância relativa** na decisão do modelo, confirmando que o vulto financeiro é o principal indutor de risco na autarquia.

III. METODOLOGIA

A. Validação Temporal Out-of-Time

O conjunto de dados foi cindido cronologicamente para refletir a realidade fiscal: registros de 2021 a 2023 foram alocados para treinamento (**1.051 registros**) e dados de 2024 e 2025 para teste (**819 registros**). Esta abordagem garante que o modelo seja testado em um "futuro" não visto durante o treino.

B. Algoritmos Avaliados

Foram testadas seis arquiteturas de aprendizado de máquina. No cenário atual, a **Regressão Logística** e o **Random Forest** apresentaram os melhores equilíbrios de separação de classe para a predição de execuções problemáticas.

C. Detecção de Anomalias e Clustering

Para a análise não supervisionada, utilizou-se o *Isolation Forest* para detecção de *outliers* e o *K-Means* ($k = 3$) para a segmentação de fornecedores. O número de agrupamentos foi validado pelos métodos do Cotovelo e Silhueta.

IV. RESULTADOS E DISCUSSÃO

A. Desempenho Preditivo

O modelo de *Logistic Regression* alcançou uma métrica **AUC-ROC de 0,73**. Embora o modelo apresente sensibilidade ao valor dos contratos, ele permite à FACAPE priorizar a fiscalização sobre os empenhos de maior vulto financeiro.

B. Detecção de Anomalias (*Isolation Forest*)

O algoritmo identificou **187 contratos** (10% da base) como anomalias estatísticas. O caso mais expressivo envolveu a Folha de Pagamento, com empenhos individuais superiores a R\$ 10 milhões, exibindo comportamentos discrepantes em relação aos padrões de fornecedores comerciais.

C. Análise por Segmentos de Risco (*K-Means*)

A clusterização estratificou os fornecedores em três níveis (Tabela I):

Tabela I
SEGMENTAÇÃO DE FORNECEDORES VIA K-MEANS

Segmento	Qtd. Fornecedores	Ticket Médio
Médio Risco	330	R\$ 388.754,68
Baixo Risco	310	R\$ 14.831,96
Alto Risco	13	Variável (Novos)

V. MONITORAMENTO E ARQUITETURA

Propõe-se uma infraestrutura de monitoramento contínuo fundamentada em:

- **Evidently AI:** Detecção de *data drift* e *concept drift*.
- **PostgreSQL:** Persistência de metadados e logs de inferência.
- **Grafana:** Visualização em tempo real e alertas via Webhooks caso o desempenho caia abaixo do *baseline*.

VI. CONCLUSÃO

A integração do MCP-Brasil permitiu uma análise fiel à realidade do TCE-PE. O modelo demonstrou alta sensibilidade ao valor dos contratos, permitindo uma governança ativa e preventiva, onde o risco de ineficiência alocativa é máximo nos contratos de maior valor. Trabalhos futuros preveem o uso de Processamento de Linguagem Natural (PLN) para análise qualitativa dos objetos contratuais.

REFERÊNCIAS

- [1] Brasil. Constituição da República Federativa do Brasil de 1988. Art. 37.
- [2] P. Chapman et al., *CRISP-DM 1.0: Step-by-step data mining guide*. SPSS inc, 2000.
- [3] F. T. Liu et al., "Isolation Forest," *8th IEEE Int. Conf. Data Mining*, 2008.